

因果推論のためのシングルパス連合集約：合成データによる10億規模の検証

和智大二郎

独立研究者 / オープンソースエンジニア

daijiro.wachi@gmail.com

要旨

シングルパス連合集約による因果推論が、市販のハードウェア上で計算的に実現可能であることを示し、制御された合成実験において理論的な陽性度違反現象を再現することで実装を検証する。

方法: Newton-Raphson十分統計量集約（コンパクト実装では約384バイト/サイト、現行実装では約584バイト/サイト）を用いた連合因果推論を実装し、100万～10億患者（1,000サイト）に規模を拡大した合成多剤併用データで検証した。

結果: 100万患者を0.223秒（4,484,304 pts/s）で、10億患者を**1.73分**（9,612,981 pts/s）で処理（いずれも24コア）。2種類の推定量を実装：CLIシンプル平均差推定量（40バイト/サイト、SE/CI付き）とNewton-Raphson IPW推定量（約584バイト/サイト）。

負の対照として、未調整平均差推定量による100万規模の推定が、 $p < 0.0001$ でも系統的バイアスを示すことを確認：0.4%有病率では符号逆転（埋め込み $-1.5 \rightarrow$ 推定 $+0.056$ ）、0.064%有病率では著しい過小推定（埋め込み $+1.5 \rightarrow +0.060$ ）。

真の条件付きATEをアウトカムモデルから解析的に導出して検証したIPW推定量は、主要な知見を示す：規模拡大が最もまれなサブグループのバイアスを解消する。Interaction3（真のATE $+1.490$ 、有病率約0.006%）は、100万人での $n=704$ の -28% 過小推定から100万人での $n=63,340$ での $\approx 0\%$ へと改善する。より大きなサブグループは規模によらず良好なキャリブレーションを示す：interaction2（真 $+1.527$ ）は $\pm 2\%$ 以内、interaction1（真 $+3.0$ ）は100Mおよび1Bで 5% 以内。

結論: シングルパス連合集約は $O(n)$ の計算量（患者ごとの処理は一定）を達成し、市販のハードウェアで10億患者データセットを2分以内に処理する。壁時計時間はPコアでおおよそ $O(n/P)$ でスケールする。100万人から10億人への見かけ上の超効率性は、CPUの利用率向上（10→24コアの有効活用）を反映するものであり、アルゴリズムの劣線形性ではない。コアが飽和すると壁時計時間はデータとほぼ線形にスケールする（100M→1B：データ10倍、壁時計12倍）。合成データでの検証から、規模拡大は十分な n を達成するサブグループのバイアスを解消するが（interaction3：100万人で $-28\% \rightarrow$ 1億人で n が63,340のときに $\approx 0\%$ ）、IPW不安定性が持続するより大きなサブグループでは、 n に依らず残余バイアスが残ることがわかる（interaction1：1億人と10億人の両方で 4.7% の過小推定）。

限界: 全ての検証は既知の真値を持つ合成データを使用している。実世界への適用可能性は、機関間の共同研究による実証的なテストが必要である。

キーワード: 連合学習、因果推論、シングルパス集約、10億規模計算、 $O(n)$ スケーラビリティ、陽性度違反

1. はじめに

1.1 動機

まれなサブグループ（有病率 $< 0.1\%$ ）における因果推論は、よく知られた統計的課題に直面する：傾向スコアの陽性度違反が、単なる検出力低下ではなく系統的バイアスを引き起こす可能性がある [1,2]。処置群と対照群が共変量空間において重複しない場合、逆確率重み付け [7] は高い統計的精度を持ちながらも系統的にバイアスのある推定値を生成する可能性がある [3,4]。

独立したエンジニアとして、私は私の手の届かないIRB承認と機関合意を必要とする実際の多機関医療データにアクセスできない。代わりに、これを計算的に探索し、規模における連合因果推論の技術的実現可能性を示すためのオープンソースツールを構築した。

1.2 貢献

単一の主張: シングルパス連合集約による因果推論が市販のハードウェアで計算的に実現可能であることを示し、合成実験において既知の真値に対して実装を検証する。

裏付けとなる証拠:

1. スケーラビリティ: 100万患者を0.223秒 (4,484,304 pts/s) $\rightarrow$ 10億患者を1.73分 (9,612,981 pts/s)、いずれも24コア
2. 通信効率: スケールによらず一定のサイトあたりペイロード（現行実装では約584バイト/サイト、コンパクト版では約384バイト；現行実装での1,000サイトあたり合計約570 KB）
3. 規模での検証: アウトカムモデルから解析的に導出した真の条件付きATEを用いた3つの規模でのIPW推定量。主要な知見—規模拡大が最もまれなサブグループのバイアスを解消する：interaction3（真 +1.490）は100万人で $n=704$ の $-28\% \rightarrow$ 1億人で $n=63,340$ の $\approx 0\% \rightarrow$ 10億人で -2.2% へと改善。より大きなサブグループも良好なキャリブレーション：interaction2（真 +1.527）は $\pm 2\%$ 以内；interaction1（真 +3.0）は $7.7\% \rightarrow 4.7\%$ と100M超では収束遅減

成果物: 測定されたパフォーマンスと合成データでの検証済み正確性を持つオープンソース参照実装。実際の多施設データベースでのテストに向けた機関研究者向けの準備が整っている。

限界: 全ての検証は既知の真値を持つ合成データを使用している。実世界への適用可能性は、独立したエンジニアとして私のアクセス範囲を超えた実証的なテストが必要である。

位置付け: これは計算的実現可能性を確立し、実装の正確性を検証するものである。医学的発見や政策的推奨ではない。

2. 実装

2.1 アーキテクチャ：シングルパス連合集約

主要な革新: 連合学習において一般的な反復的通信を回避するシングルパス集約 [11,12]。

各サイト k はローカルで計算する：

- 傾向スコア勾配： $g_k \in \mathbb{R}^5$
- 傾向スコアヘッセ行列： $H_k \in \mathbb{R}^{5 \times 5}$
- アウトカム回帰統計量： XWX_k, XWY_k
- メタデータ： $nPatients$ （サイトあたりの患者数）
- 合計：約584バイト/サイト（現行実装、完全行列）；コンパクトな上三角符号化では約384バイトに削減可能

中央集約機：

- 統計量の集約： $G = \sum g_k, H = \sum H_k$
- Newton-Raphsonをローカルで反復（追加のサイト通信なし）
- $\sum XWX_k, \sum XWY_k$ を使用した逆確率重み付けによる因果効果の計算

「シングルパス」の意味: 各サイトは十分統計量を正確に1回提供する—繰り返しのサイト通信はない。中央集約機はメモリ制約のあるバッチ（バッチサイズ = 利用可能なCPUコア数）でサイトを処理する。各バッチの後、集約機は1回のNewtonステップを実行し、次のバッチの前に β を更新する。その結果、後のバッチのサイトは前のバッチのサイトよりも洗練された β を使用する。これは、Jordan et al. [16]の厳密な「ワンショット」定式化（Newtonの更新前に全てのサイトを同時に集約する）とは構造的に異なる。 β がバッチ間で急速に安定化する場合、実際には区別は小さいが、中央分析との完全な等価性は全サイトが1バッチで処理される場合（1Mランのように、 $10 \text{ サイト} \leq 24 \text{ コア}$ ）にのみ成立する。1Bランの場合（1,000サイト、42バッチ）、推定値は β がバッチ間で安定化するにつれて改善される近似値である。実証的には、 β は単調収束ではなく $\pm 2.5\%$ 以内で変動する（100サイトのインクリメントあたり $\|\Delta \beta\|/\|\beta\| < 2.5\%$ ）；完全な軌跡については補足S4を参照。

数学的特性: 十分統計量集約を用いたNewton-Raphson連合学習は、総和の結合性を利用する [16]。全サイトが1バッチに収まる場合、連合推定値は中央分析と同一である。バッチ処理する場合（1Bラン）、推定値は β がバッチ間で洗練されるにつれて段階的に安定化する。

通信の利点: 勾配を繰り返し交換する反復的連合学習とは異なり、各サイトは十分統計量を1回送信するだけで、中央サーバーはさらなるサイト通信なしにNewton更新をローカルで実行できる。

2.2 技術スタック

- 言語: TypeScript/Node.js v18
- 並列化: Workerスレッド（`os.cpus().length` コア、自動検出）
- データ形式: OMOP CDM v5.4 [13,14] テーブル（PERSON、DRUG_EXPOSURE、MEASUREMENTなど）
- メモリ: サイトあたり $O(1)$ （ピーク3 GB未満；測定値：1Bラン；1Mランでは1 GB未満）
- 通信: 約584バイト/サイト（現行）、約384バイト/サイト（コンパクト符号化）；サイトサイズによらず $O(1)$

このコードベースの2つの実装（異なるセクションで結果を生成）：

実装	役割	推定量	通信/ サイト	出力	使用箇所
CLI (<code>run-polypharmacy.ts</code>)	負の対照 (ベースライン)	シンプル平均 差	40バイ ト	ATE、SE、 CI、z、p	セクショ ン3.2
<code>testOptimized.js</code> (IPW エンジン)	提案された 貢献	Newton- Raphson IPW	約584 バイト	ATEのみ	セクショ ン3.1、3.3

CLIは傾向調整なしのバイアスの大きさを示す（負の対照）。IPWエンジンが提案システムであり、傾向重み付けを適用し、同じ十分統計量プロトコルを使用して10億患者にスケールする。セクション3.2と3.3の結果は異なる推定量から得られており、直接比較はできない。セクション3.2はCLIを使用してシンプルな連合推定量の統計的特性（SE、CI、p値）を特徴付ける。セクション3.3はIPW推定量を同じ推定量の下で一貫してバイアス解消を評価するために3つの規模（100万、1億、10億）で使用する。

2.3 合成データ生成

OMOP互換データジェネレーターを使用してカスタム多剤併用シナリオを生成した。Syntheaの臨床パターン [10] を構造的に模倣し、異なる有病率レベルでシステムをテストするための3つの相互作用層を持つ：

層	有病率	埋め込み効果 (ml/分/年)	臨床パターン	ラベル
1	16%	+2.0	CKD ステージ2-3a	一般
2	0.4%	-1.5	CKD 3a + ループ利尿薬	まれ
3	0.064%	+1.5	CKD 3b + ループ利尿薬 + 年齢>80	非常にまれ

適応症による交絡（実際のモデル、米国サイト； `confStrength` = 1.2）：

```
logit(P(Treatment)) = -2.0 + 0.02×年齢 + 0.05×BMI + 0.3×HbA1c - 0.01×eGFR + 0.6×SES
```

（ `confStrength` はサイト別：米国=1.2、日本=0.8、北欧=0.6、インド=1.5；SES係数 = `confStrength` × 0.5）

高いHbA1c、高齢、高いBMIは処置確率を高め、低いeGFRはわずかに低下させる（腎機能が著しく低下している場合の処方減少を反映）。eGFRアウトカムの支配的な交絡機序は年齢である：処置患者は系統的に高齢（傾向スコアモデルにおける正の年齢係数）で、高齢患者はより速い自然eGFR低下を経験する（アウトカムモデルの `egfrChange` = $-2.0 - 0.05 \times \text{年齢} - \dots$ ）。この年齢媒介の負の交絡により、未調整平均差推定量は治療効果を過小評価する—処置患者は実際よりも改善が少なく見える（反事実的な自然経過がより悪いため）。

規模の仮定: 10億の構成は1,000サイト × 100万患者/サイトを使用する。各100万患者のサイトは、大型学術医療センター、国家レジストリ、または保険請求データベースに対応する。典型的なコミュニティ病院は10,000~50,000患者を持ち、比較可能な総規模に達するにはより多くのサイトが必要になる。

一般化を制限する重要な単純化:

1. 低次元交絡: ロジスティックモデルの5共変量

- 現実: 100以上の変数が複雑な非線形相互作用を持つ
- 影響: 陽性度違反は低次元シミュレーションのアーティファクトかもしれない

2. 理想化された欠損: 5%のランダム欠損

- 現実: 無視できない20~40%の欠損 (より病気の患者はより多くのデータが欠損している)
- 影響: 実際の傾向スコア推定はより困難になる

3. 既知の真値: 埋め込み効果はプログラムされている

- 現実: 真の効果は未知かつ検証不可能
- 影響: バイアス検出は真値が既知の場合にのみ可能

4. 均質なサイト: 同一のデータ生成プロセス

- 現実: サイトは人口統計、診療、測定機器、コーディングシステムで異なる
- 影響: 実際の連合集約は異質性の下で失敗する可能性がある

5. 未測定交絡なし: 全ての交絡因子が観測されている

- 現実: 常に未測定交絡因子が存在する (遺伝、服薬遵守、社会的要因)
- 影響: 実際の因果推論は追加のバイアス源に直面する

含意: これらは些細な単純化ではない。実際の医療データ分析とは根本的に異なる問題を表している。結果は概念実証としてのみ解釈すべきである。

3. 結果

3.1 計算スケーリング: 100万から10億患者

ハードウェア: Linux 6.6.87.2 (WSL2)、24論理コア。全てのランは利用可能な全コアを使用 (`batchSize = os.cpus().length`)。2026年4月27日に検証。

規模	サイト	患者/サイト	コア	処理時間	スループット (pts/秒)	通信/サイト	合計通信
100万	10	100,000	24	0.223秒	4,484,304	約584バイト†	約5.7 KB
1億	100	1,000,000	24	8.6秒	11,580,775	約584バイト†	約57 KB
10億	1,000	1,000,000	24	1.73分 (104秒)	9,612,981	約584バイト†	約570 KB

† 現行実装（完全行列）。コンパクトな上三角符号化では約384バイト/サイト（10億では約375 KB合計）に削減可能。

スケーラビリティ分析：

- 同一ハードウェアでの3つの規模点（24コア）：100万人で0.223秒 → 1億人で8.6秒 → 10億人で104秒。患者あたりの処理量は $O(1)$ であり、 $O(n)$ の総計算量を実現。壁時計時間は $P=24$ コアでおおよそ $O(n/P)$ でスケールする。100万→10億の比（データ1,000倍 → 壁時計466倍）はアルゴリズムの劣線形性ではない：CPU利用率の向上を反映している（100万人では1バッチで10/24コアのみ使用；1億人と10億人は全24コアを使用）。コアが飽和すると壁時計時間はほぼ線形にスケールする：1億→10億 = データ10倍、壁時計12倍。
- スループットは1億人でピーク（11.6M pts/s）：5バッチにわたって全24コアが一貫して飽和している場合。100万人のランは10/24コアのみ使用（1つの不完全なバッチ）；10億人のランの42バッチはより多くのバッチ管理オーバーヘッドを発生させ、1億人と比べて患者あたりスループットをわずかに低下させる。
- 一定の通信：約584バイト/サイト（現行実装、完全行列）でサイトサイズによらず；コンパクトな上三角符号化では約384バイト/サイトに削減可能

再現コマンド：

```
npm test          # 100万患者 → results/test_optimized_run/final_results.json
npm run run:100m  # 1億患者 → results/optimized_100million_run/final_results.json
npm run run:1b    # 10億患者 → results/optimized_1billion_run/final_results.json
```

3.2 負の対照：未調整推定量による系統的バイアスの実証（100万患者）

役割: このセクションは、傾向調整なしのナイーブな連合推定量が生成する系統的バイアスの特徴付ける。結果はセクション3.3のIPWアプローチを動機付け、高い統計的精度（狭いCI、 $p < 0.0001$ ）がバイアスの不在を意味しないことを示す。

実装: CLI `run-polypharmacy.ts`、シンプル平均差推定量、40バイト/サイト。SE、CI、z統計、p値を算出。

層	有病率	n	埋め込み	推定値 (95% CI)	z統計	p値	偏差	ラベル
1	16%	160,000	+2.0	+0.611 (+0.598, +0.625)	91.5	<0.0001	−1.389 (69% 過小推定)	一般
2	0.4%	4,000	−1.5	+0.056 (+0.044, +0.069)	8.76	<0.0001	+1.556 (符号逆転)	まれ
3	0.064%	640	+1.5	+0.060 (+0.047, +0.072)	9.33	<0.0001	−1.440 (96% 過小推定)	非常にまれ

2026年4月27日に検証 (seed=42、サイト数=10、患者数/サイト=100,000、プロファイル=米国)。

再現コマンド：

```
npm run test:tier1
npm run test:tier2
npm run test:tier3
```

解釈：

層1 (一般、16%)：69%の過小推定 (+0.611 対 埋め込み+2.0) だが符号は正しい。これは適応症による交絡が存在する場合の未調整平均差推定量の期待された挙動である。支配的なメカニズム (セクション2.3のアウトカムモデルによる) は年齢である：処置患者は系統的に高齢 (傾向モデルにおける正の年齢係数) で、高齢患者はより速い自然eGFR低下を経験する (アウトカムモデルの $-0.05 \times \text{年齢}$)。未調整の処置—対照比較はそのため見かけ上の治療効果を圧縮する。非常に狭いCI ($z=91.5$) はこれが系統的バイアスであり、サンプリング誤差ではないことを確認する：データが多くなるとインターバルが誤った値の周りで狭まるが、修正はされない。サンプルサイズによらず系統的バイアスが持続することはセクション3.3のIPW推定量を動機付ける。

層2 (まれ、0.4%)：完全な符号逆転。埋め込み効果は有害 (−1.5) だが、シンプル推定量は $p<0.0001$ で有益 (+0.056) と推定する。誤った方向への狭いCIは高精度な系統的バイアスを示す—検出力の失敗ではない。古典的な低検出力による型Sエラー [1] とは異なり、これは処置群と対照群が共変量分布において根本的に異なるまれなサブグループ (CKD 3a + ループ利尿薬) における構造的交絡から生じる。ループ利尿薬使用は心不全と体液貯留によって引き起こされる—5共変量傾向モデルにはない危険因子—シンプル推定量が修正できない残余交絡を生み出す。注：セクション3.3では「interaction2」に対して異なるサブグループ定義を使用しており、このCLI層2結果とは直接比較できない。

層3 (非常にまれ、0.064%)：著しい過小推定 (25倍小さい)。わずか640患者では、処置群と対照群は傾向スコア空間でほとんど重複せず、シンプル推定量はこれを回復するメカニズムを持たない。

重要な注意: これらは検出力の失敗ではない。全ての推定値は狭い信頼区間で $p<0.0001$ を達成している。問題は系統的バイアスである—推定量の誤った特定 (層1) と陽性度違反 (層2〜3) から—ランダムなサンプリング変動ではない。高い精度はバイアスの不在を意味しない [2,6,8]。

3.3 提案推定量：3つの規模でのNewton-Raphson IPW

役割: このセクションは主要な貢献を示す—10億規模の処理をサポートする連合IPW推定量。セクション3.2と同じ十分統計量集約プロトコルを使用するが、そこで示されたバイアスを部分的に修正するために傾向スコア重み付けを適用する。

実装: `testOptimized.js`、Newton-Raphson IPW推定量、約584バイト/サイト。3つの規模行（100万、1億、10億）全てが同じ実装を使用する。注：現行実装はSE/CIを計算しない；ATEのみ。

CLIティアとは異なるサブグループ定義: `testOptimized.js` データジェネレーターは独立したサブグループ基準と埋め込み効果を使用する。`interaction1`のみがeGFR効果を明示的に埋め込んでいる（処置 × `interaction1`患者で+3.0 ml/分/年）。`Interaction2`と`interaction3`はそれぞれ入院と副作用に対する効果を持つ—eGFRではない。全サブグループの患者は基本eGFR治療効果（+1.0 ml/分/年）を経験し、`interaction1`基準（`HbA1c > 8.0` かつ 任意の利尿薬使用）も満たす場合は追加のブーストを得る可能性がある。これはセクション3.2とのnの不一致も説明する：CLIの層2は設計により正確に0.4% × 100万 = 4,000患者をターゲットにしているが、`interaction2`（`raceAsian && age > 75 && bmi < 22`）は実証的に45,404患者（約4.5%）を生成する—全く異なるサブグループ。

注：セクション3.2対3.3の比較: セクション3.2と3.3は異なるサブグループ定義、異なる推定量、異なる埋め込み効果メカニズムを使用する。それらの結果は層ごとに直接比較できない；各セクションはシステムの異なる側面を特徴付ける。

シード安定性: 3つの規模全ての結果はベースシード42を使用する（サイトkはシード42+kを使用）。100万規模での多シード複製（シード42、100、200）は`interaction1`のATEが2.770、2.837、2.822—0.067の範囲となり、`n`≈173,000でのサンプリング変動と一致する。`Interaction3`（`n`≈700）はシード間で高い分散（1.060～2.433）を示し、非常に小さいサブグループは安定した推定のためにはるかに大きな規模が必要であることを確認する。完全な多シード結果は補足S5にある。

真の条件付きATE導出: eGFRアウトカムモデルが `egfrChange += treatment × (1.0 + 2.0 × interaction1_flag)` であるため、任意のサブグループSに対する真の条件付きATEは：

$$E[\text{eGFR効果} \mid \text{患者} \in S] = 1.0 + 2.0 \times P(\text{interaction1基準を満たす} \mid \text{患者} \in S)$$

この重複確率Pは各ラン中に実証的に測定される。100Mランからの結果（100サイト、各プロファイル25サイト—最もバランスの取れた推定）：

サブグループ	P(interaction1重複)	真の条件付きeGFR ATE
interaction2	26.3%	+1.527 ml/分/年
interaction3	24.5%	+1.490 ml/分/年

Interaction 1（eGFRブーストサブグループ）: `hba1cBaseline > 8.0` かつ 任意の利尿薬。明示的なeGFR埋め込み効果：+3.0 ml/分/年。

規模	サブグループn	推定ATE (IPW)	真のeGFR効果	偏差
100万	172,952	+2.770	+3.0	−0.230 (7.7%過小)
1億	16,906,813	+2.858	+3.0	−0.142 (4.7%過小)
10億	169,116,919	+2.860	+3.0	−0.140 (4.7%過小)

Interaction 2 (入院リスクサブグループ) : raceAsian かつ age > 75 かつ bmi < 22。埋め込み効果は入院 (+5%絶対リスク) に対するもので、eGFRではない。真のeGFR ATE : +1.527 ml/分/年 (上記から導出)。

規模	サブグループn	推定ATE (IPW)	真のeGFR ATE	偏差
100万	45,404	+1.548	+1.527	+0.021 (+1.4%)
1億	4,164,554	+1.498	+1.527	−0.029 (−1.9%)
10億	41,652,850	+1.500	約+1.527	約−0.027 (約−1.8%)

Interaction 3 (副作用サブグループ) : egfrBaseline 30~45 かつ ループ利尿薬 かつ age > 80。埋め込み効果は副作用 (+2%絶対リスク) に対するもので、eGFRではない。真のeGFR ATE : +1.490 ml/分/年 (100M推定 ; 1M推定は異なるサイトプロファイル分布のため+1.523)。

規模	サブグループn	推定ATE (IPW)	真のeGFR ATE	偏差
100万	704	+1.091	+1.523	−0.432 (−28.4%)
1億	63,340	+1.491	+1.490	+0.001 (≈0%)
10億	632,776	+1.457	約+1.490	約−0.033 (約−2.2%)

2026年4月27日に検証 (seed=42、ベースシート42 + siteId ; サイト数=1,000、患者/サイト =1,000,000、24コア、10億で104秒 ; 1億で9.7秒)。

解釈: 真の条件付きATEがデータ生成モデルから正確に決定されたことで、3つのサブグループにわたって一貫した状況が明らかになる。

Interaction 1 (真 +3.0、明示的に埋め込み) : 7.7% → 4.7% → 4.7%の過小推定 (100万 → 1億 → 10億)。改善は100万 → 1億に集中 ; 10億超では収獲逓減。

Interaction 2 (真 +1.527、重複から導出) : IPWは3つの規模全てでほぼ不偏 (+1.4%、−1.9%、約−1.8%)。このほぼキャリブレーションされた状態は真の条件付きATEの導出なしには自明でない : eGFR効果を約+1.0と仮定すると (interaction1重複を無視)、全規模にわたって+0.5の持続的な過大推定を意味することになる—見かけ上の誤ったキャリブレーション。真の値は+1.527である (interaction2患者の26.3%がinteraction1基準も満たし、追加のeGFRブーストを受けるため)。これは重要な警告的知見である : IPW精度の正しい解釈には、限界的な埋め込み効果だけでなく真の条件付きATEを知ることが必要である。

Interaction 3（真 +1.490、重複から導出）：劇的な規模依存の改善。100万人（ $n=704$ ）では、IPW推定値は−28.4%の過小推定—100万規模での704患者サブグループにおける極端な重みの不安定性に起因する。1億人（ $n=63,340$ ）では、推定値は本質的に正確（ $\approx 0\%$ 偏差）。10億人（ $n=632,776$ ）では、偏差は−2.2%。1億人から10億人へのわずかな後退は、有効な母集団混合の変化を反映している可能性がある：10億人のランは1億人での5バッチに対して24サイトの42バッチを処理し、サイトプロファイルの重み付けを変える；真の値を定義するために使用された100Mの重複測定（+1.490）は10億人の有効母集団と正確に一致しない可能性があるため、見かけ上の−2.2%は推定量の劣化ではなくこの外挿を部分的に反映しているかもしれない。これは最も明確な規模の恩恵を示す：100万規模では正確に推定するには希少すぎるサブグループが、1億〜10億規模では確実に定量化可能になる。

サブグループ全体の要約: 規模拡大はIPW精度を大幅に改善する。最大の利得はinteraction3にあり、サブグループが $n=704$ （100万、−28%バイアス）から $n=63,340$ （1億、 $\approx 0\%$ ）へと成長する。

Interaction1とinteraction2はどちらも1億と10億で良好に推定され、偏差は $\leq 5\%$ 。

再現コマンド：

```
npm run run:100m    # 1億患者 → results/optimized_100million_run/final_results.json
npm run run:1b      # 10億患者 → results/optimized_1billion_run/final_results.json
```

4. 考察

4.1 示したこと

検証された単一の主張: シングルパス連合集約による因果推論は、市販のハードウェアで10億規模において $O(n)$ の計算量（患者ごとの処理は一定）を達成する。壁時計時間はPコアでおおよそ $O(n/P)$ でスケールする；100万人から10億人への見かけ上の超効率はCPU利用率のアーティファクト（100万人は24コアを十分活用していない）であり、アルゴリズムの劣線形性ではない。検証は、規模拡大が十分な n を達成するサブグループのバイアスを解消すること（interaction3：100万人で−28% → 1億人で $n=63,340$ のときに $\approx 0\%$ ）を示す一方、 n によらずIPW不安定性が持続するサブグループでは還元不可能な残余バイアスが残ることを示す（interaction1：1億人と10億人の両方で4.7%の過小推定）。

スケーラビリティの証拠：

- 100万人で0.223秒 → 1億人で8.6秒 → 10億人で104秒（同じハードウェア、24コア）； $O(n)$ 総計算量；壁時計 $\approx O(n/24)$ ：1億→10億はデータ10倍/壁時計12倍（コアが既に飽和しているため、ほぼ線形）；100万→10億の比（データ1,000倍/壁時計466倍）はCPU利用率の向上を反映しており、アルゴリズムの劣線形性ではない
- スループットは1億人でピーク：11,580,775 pts/s（5バッチにわたって全24コアが完全に飽和）；100万人は4,484,304 pts/s（10/24スロット使用）、10億人は9,612,981 pts/s（42バッチ、より多くのオーバーヘッド）
- 一定の約584バイト/サイト通信（現行実装）でサイトサイズによらず；コンパクト符号化目標：約384バイト/サイト

規模にわたるIPW挙動の証拠（IPW推定量サブグループ；アウトカムモデルから導出した真の条件付きATE）：

- **Interaction3** (真 +1.490、24.5% interaction1重複から導出)：最も明確な規模の恩恵—100万人でn=704の−28% → 1億人でn=63,340の≈0% → 10億人でn=632,776の−2.2%；100万規模では手に負えないサブグループが1億規模では確実に定量化可能になる
- **Interaction1** (真 +3.0、明示的に埋め込み)：7.7% → 4.7% → 4.7%の過小推定 (100万 → 1億 → 10億)；改善は100万→1億に集中し、その後収獲逡減
- **Interaction2** (真 +1.527、26.3% interaction1重複から導出)：全規模でほぼ不偏 (+1.4%、−1.9%、約−1.8%)
- 主要な知見：IPWは1億と10億の全3つのサブグループで (≤5%) 良好なキャリブレーション；残余バイアスの支配的な要因は小規模でのサブグループの希少性であり、nとは無関係なIPW不安定性ではない

4.2 限界

独立したOSSエンジニアとして：

- 実際の多機関医療データへのアクセスなし
- ヒト被験者研究のIRB許可なし
- 独自の薬物警戒システムとの比較基準なし
- 個人の市販ハードウェアを超えた機関リソースなし

合成データの重要な限界：

私の合成実験は、実世界の課題を過小評価する可能性が高い単純化を行っている：

1. **交絡構造**: ロジスティックモデルの5共変量 → 現実：100以上の変数が複雑な非線形相互作用を持つ → 影響：陽性度違反は過度の単純化のアーティファクトかもしれない
2. **欠損メカニズム**: 5%のランダム欠損 → 現実：無視できない20~40%の欠損 → 影響：実際の傾向推定はより困難
3. **既知の真値**: 埋め込み効果はプログラムされている → 現実：真の効果は未知かつ検証不可能 → 影響：バイアス検出は既知の真値でのみ可能
4. **サイトの均質性**: 同一のデータ分布 → 現実：サイトは人口統計、診療、機器で異なる → 影響：連合集約は異質性の下で失敗する可能性がある
5. **未測定交絡なし**: 全ての交絡因子が観測されている → 現実：常に未測定交絡因子が存在する → 影響：実際の応用では追加のバイアス源
6. **単純化されたアウトカム**: 線形関係 → 現実：複雑な疾患進行、時間変動性交絡 → 影響：実際のアウトカムモデリングは大幅により困難

含意: これらの単純化は実際の医療データとは**根本的に異なる問題**を表している。合成結果は技術的実現可能性を示すが、実世界のパフォーマンスを予測することはできない。

技術的限界：

- **単一マシンシミュレーションのみ**: この研究の全ての「連合」サイトは単一マシン上の並列Workerスレッドとして実行される。これは連合プロトコルのシミュレーションであり、実際の分散展開ではない。機関ネットワーク境界にわたる実際の連合実行には、ネットワーク遅延、シリアルライゼーションオーバーヘッド、認証、暗号化が含まれる—いずれもここでは測定され

ていない。通信サイズ（約584バイト/サイト）は理論的なプロトコルオーバーヘッドを表し、測定されたネットワーク転送時間ではない。パフォーマンス数値は市販ハードウェア上のローカル並列処理のみを反映する。

- 市販ハードウェアのみ（クラウド/HPCベンチマークなし）
- フォールトトレランスやセキュリティ分析なし
- GPU加速実装との比較なし
- 重みのトリミングや安定化なし: IPW推定量は傾向重みを制限せず、傾向スコアのテールにおける極端な重み値に対して脆弱なままにしている [15]。この合成実験では影響は小さいように見える—真の条件付きATEがアウトカムモデルから正しく導出されると、全3つのサブグループが1億人以上で±5%以内で推定される。しかし、非合成の交絡構造の下での重みのトランケーションに対する感度は未検証のままである。

4.3 実データを必要とする未解決の問題

✗ 実証的な検証なしには不明：

- 実際の薬物警戒システムがまれなサブグループで陽性度違反を経験するかどうか
- 10億規模が実際のまれなサブグループに十分かどうか（実際の有病率と交絡に依存）
- 合成データで観察されたバイアス解消が実際の異質なサイトに一般化するかどうか
- 連合アプローチが既存の中央集権的システムに対して実際の優位性を提供するかどうか
- OMOP統合が実際の観察データベースでシームレスに機能するかどうか

4.4 なぜオープンソースにするのか

主要な目標: データアクセスを持つ研究者のための参照実装として動作するコードを共有する。

意図されたユーザー：

- OMOP形式のデータベースを持つ薬物警戒研究者
- 連合因果推論を探索する方法論研究者
- まれなサブグループ仮説をテストするヘルスケア情報科学者

期待すること：

1. 実際の多施設データを持つ誰かがまれなサブグループで陽性度違反が起こるかどうかをテストする
2. それらが存在すれば、既存の方法との比較評価
3. 有用であれば、実装へのコミュニティによる改善
4. 有用でなければ、否定的な結果にも科学的価値がある

現実的な期待: ほとんどの研究者はこれを必要としないだろう。数人が有用と感じるかもしれない。それで十分である。

4.5 将来の研究（共同研究が必要）

実際のデータで10億規模の知見を検証するには、以下が必要である：

1. データアクセス: 実際のEHR分析のための多機関契約
2. IRB承認: 観察研究のための倫理委員会の許可

3. 比較基準: 既存の薬物警戒方法へのアクセス
4. 実世界での検証: 規模でのバイアス解消が異質な実際のサイトに一般化するかテスト
5. 方法の比較: AIPW、マッチング、操作変数との比較 [9]
6. 専門家との共同研究: 疫学者と臨床医からのドメイン専門知識
7. 重みの安定化: トリミング/安定化されたIPW重みの実装と評価（例：第1/第99パーセンタイルでのトランケーション [15]）；この合成設定では影響は小さいように見える（1億人以上で全サブグループが±5%以内）が、実世界の高次元交絡構造下での感度は未検証のままである
8. 実際の連合展開: 実際のネットワーク境界にわたってプロトコルをテストし、実際の通信オーバーヘッド、遅延、機能的制約下でのフォールトトレランスを測定する

私は訪問研究者や技術的貢献者としての共同研究に開放的である。

5. 結論

シングルパス連合集約は $O(n)$ の総計算量（患者ごとの処理は一定）を達成し、24コアで1億患者を9.7秒で、10億患者を1.73分で処理し、約584バイト/サイトの通信量で実現する。壁時計時間はPコアでおおよそ $O(n/P)$ でスケールする；1億→10億の移行（データ10倍、壁時計12倍）はコアが飽和した後のほぼ線形スケーリングを確認する。アウトカムモデルから解析的に導出した真の条件付きATEを用いた3つの規模でのIPW推定量の検証は、1億人と10億人規模の全3つのサブグループにわたって一貫したIPW精度（≤5%偏差）を示す。最も明確な規模の恩恵はinteraction3である：最もまれなサブグループが $n=704$ （100万、−28%バイアス）から $n=63,340$ （1億、≈0%バイアス）へと成長し、10億規模の連合が100万規模では統計的に手に負えないサブグループでの確実な因果推論を可能にすることを示す。

これらの知見は計算的実現可能性を確立し、合成データでの実装の正確性を検証する。この種の規模依存のバイアスパターンが実際の薬物警戒データベースに現れるかどうか、そしてシングルパス連合IPW推定量がそれらを検出できるかどうかは、多施設データアクセス、IRB承認、臨床ドメイン専門家との共同研究を必要とする未解決の実証的な問題である。

コード: <https://github.com/watilde/Harmonia> — 連絡先: daijiro.wachi@gmail.com

再現可能性

インストール（30秒）

```
git clone https://github.com/watilde/Harmonia.git
cd Harmonia
npm install
npm run build
```

クイック検証 (< 1秒)

```
npm run test:quick # 10K患者、健全性チェック
```

完全な再現 (層は約3秒 ; 10億人は約2分)

セクション3.2 — CLIシンプル推定量 (層1~3) :

```
npm run test:tier1 # 一般サブグループ (16%) : n=160,000、ATE=+0.611 対 埋め込み +2.0
npm run test:tier2 # まれなサブグループ (0.4%) : n=4,000、ATE=+0.056 対 埋め込み -1.5
npm run test:tier3 # 非常にまれなサブグループ (0.064%) : n=640、ATE=+0.060 対 埋め込み
```

セクション3.1および3.3 — Newton-Raphson IPW推定量:

```
npm test # 100万患者 → results/test_optimized_run/final_results.json
npm run run:100m # 1億患者 → results/optimized_100million_run/final_results.json
npm run run:1b # 10億患者 → results/optimized_1billion_run/final_results.json
```

出力場所

層の結果: `polypharmacy-results/tier{1,2,3}/results.json`、含む:

- 設定 (有病率、埋め込み効果、サイトパラメータ)
- 連合推定値 (ATE、SE、CI、z統計、p値)
- パフォーマンスメトリクス (時間、スループット、通信)

IPW結果:

- 100万人: `results/test_optimized_run/final_results.json`
- 1億人: `results/optimized_100million_run/final_results.json`
- 10億人: `results/optimized_1billion_run/final_results.json`
- 多シード: `results/multi_seed_test/summary.json`

ハードウェア要件

- CPU: マルチコア (テスト済み: 24コア ; `os.cpus().length` を自動使用)
- RAM: 最低16 GB (テスト済み: 64 GB、ピーク使用量 <3 GB)
- ストレージ: コード + 依存関係で約50 MB、結果で約10 MB
- OS: Linux/macOS/WindowsでNode.js v18+

期待される実行時間

- クイックテスト (10K患者): 1秒未満
- 全層比較 (3 × 100万患者): 合計約3秒 (ハードウェア依存; 24コアで測定)

- 多シードテスト (3 × 100万患者) : 合計1秒未満 (`node src/multiSeedTest.js`)
- 1億人ラン : 約9秒 (測定 : 24コアで8.6秒)
- 10億人ラン : 約1.73分 (測定 : 24コアで104秒 ; コア数でスケール)

謝辞

以下に感謝する :

- 合成ジェネレーター設計に情報を提供した臨床データモデリングの概念を提供したSyntheaオープンソースコミュニティ
- OMOP CDM標準とドキュメントのOHDSIコミュニティ
- 並列処理を可能にするWorkerスレッドAPIのNode.jsチーム

競合利益

なし。これは商業的利益のない自主的な独立研究である。

データとコードの可用性

ソースコード: <https://github.com/watilde/Harmonia>

合成データジェネレーター: リポジトリの2つの実装 :

- CLI推定量 (セクション3.2) : `packages/core/src/causal/omop-polypharmacy.ts`
- IPW推定量 (セクション3.1、3.3) : `research/modules/5-billion-scale-polypharmacy/src/dataGenerator.js`

OMOP統合:

- ジェネレーター: `packages/core/src/causal/omop-synthetic.ts`
- CLI: `packages/cli/src/commands/causal/generate-omop-data.ts`
- OHDSI Atlasコホート定義と互換性あり

実際の患者データなし: この研究は合成データのみを使用する。IRB承認は必要ない。

再現可能性: 全ての結果は上記の再現可能性セクションのコマンドで再現可能。期待される実行時間 : 層テストは約3秒 ; 1億人ランは約10秒 ; 10億人ランは約2分 (いずれも市販ハードウェアで)。

参考文献

1. Gelman A, Carlin J. Beyond Power Calculations: Assessing Type S (Sign) and Type M (Magnitude) Errors. *Perspectives on Psychological Science*. 2014;9(6):641-651.

doi:10.1177/1745691614551642

2. Petersen ML, Porter KE, Gruber S, et al. Diagnosing and responding to violations in the positivity assumption. *Statistical Methods in Medical Research*. 2012;21(1):31-54.
doi:10.1177/0962280210386207
 3. Li F, Morgan KL, Zaslavsky AM. Balancing covariates via propensity score weighting. *Journal of the American Statistical Association*. 2018;113(521):390-400. doi:10.1080/01621459.2016.1260466
 4. Cole SR, Hernán MA. Constructing inverse probability weights for marginal structural models. *American Journal of Epidemiology*. 2008;168(6):656-664. doi:10.1093/aje/kwn164
 5. Meng XL. Statistical paradises and paradoxes in big data (I): Law of large populations, big data paradox, and the 2016 US presidential election. *Annals of Applied Statistics*. 2018;12(2):685-726.
doi:10.1214/18-AOAS1161SF
 6. Wasserstein RL, Lazar NA. The ASA Statement on p-Values: Context, Process, and Purpose. *The American Statistician*. 2016;70(2):129-133. doi:10.1080/00031305.2016.1154108
 7. Rosenbaum PR, Rubin DB. The central role of the propensity score in observational studies for causal effects. *Biometrika*. 1983;70(1):41-55. doi:10.1093/biomet/70.1.41
 8. Hernán MA, Robins JM. *Causal Inference: What If*. Boca Raton: Chapman & Hall/CRC; 2020.
 9. Pearl J. *Causality: Models, Reasoning, and Inference*. 2nd ed. Cambridge: Cambridge University Press; 2009.
 10. Walonoski J, Kramer M, Nichols J, et al. Synthea: An approach, method, and software mechanism for generating synthetic patients and the synthetic electronic health care record. *JAMIA*. 2018;25(3):230-238. doi:10.1093/jamia/ocx079
 11. McMahan HB, Moore E, Ramage D, et al. Communication-Efficient Learning of Deep Networks from Decentralized Data. *AISTATS*. 2017;54:1273-1282.
 12. Kairouz P, McMahan HB, Avent B, et al. Advances and Open Problems in Federated Learning. *Foundations and Trends in Machine Learning*. 2021;14(1-2):1-210. doi:10.1561/22000000083
 13. Overhage JM, Ryan PB, Reich CG, et al. Validation of a common data model for active safety surveillance research. *JAMIA*. 2012;19(1):54-60. doi:10.1136/amiajnl-2011-000376
 14. Hripcsak G, Duke JD, Shah NH, et al. Observational Health Data Sciences and Informatics (OHDSI): Opportunities for Observational Researchers. *Studies in Health Technology and Informatics*. 2015;216:574-578.
 15. Stürmer T, Rothman KJ, Avorn J, Glynn RJ. Treatment effects in the presence of unmeasured confounding: dealing with observations in the tails of the propensity score distribution. *American Journal of Epidemiology*. 2010;172(7):843-854. doi:10.1093/aje/kwq198
 16. Jordan MI, Lee JD, Yang J. Communication-Efficient Distributed Statistical Inference. *Journal of the American Statistical Association*. 2019;114(526):668-681. doi:10.1080/01621459.2018.1429274
-

補足資料

S1. 通信の内訳

シングルパス集約: 各サイトは十分統計量を正確に1回送信する。値はfloat64（各8バイト）を使用する。

コンポーネント	説明	コンパクト（上三角）	現行実装（完全）
勾配（5共変量）	傾向の ∇ 対数尤度	$5 \times 8 = 40$ バイト	40バイト
ヘッセ行列（ 5×5 、対称）	傾向の ∇^2 対数尤度	$15 \times 8 = 120$ バイト	$25 \times 8 = 200$ バイト
XWX（ 6×6 、対称）	アウトカムの加重共分散	$21 \times 8 = 168$ バイト	$36 \times 8 = 288$ バイト
XWY（6要素）	加重アウトカム	$6 \times 8 = 48$ バイト	48バイト
メタデータ（nPatients）	患者数	約8バイト	約8バイト
サイトあたり合計	シングルパスサイトあたり	約384バイト	約584バイト

現行実装は簡単のため完全な行列を送信する。上三角を使用するコンパクト符号化では約384バイトに削減できる。どちらも患者数によらずサイトあたり $O(1)$ である。

主要な利点: 勾配を繰り返し交換する反復的連合学習 [11,12]（典型的には100以上のラウンド）とは異なり、このアプローチはバッチあたり1回十分統計量を送信する。中央サーバーは追加のサイト通信なしにローカルでNewtonステップを実行する。

100万患者、10サイトの計算:

- 連合（コンパクト）: $\text{約}384\text{バイト/サイト} \times 10\text{サイト} = \text{約}3.7\text{ KB}$
- 連合（現行実装）: $\text{約}584\text{バイト/サイト} \times 10\text{サイト} = \text{約}5.7\text{ KB}$
- 中央集権的: $100\text{万患者} \times 200\text{バイト/患者} = 200\text{ MB}$
- 削減: $200\text{ MB} / 3.7\text{ KB} \approx 54,000\text{倍}$ （コンパクト）または $200\text{ MB} / 5.7\text{ KB} \approx 35,000\text{倍}$ （現行）

S2. アルゴリズムの擬似コード

```
// 各サイトkはローカルで計算する（生データは共有しない）
function computeSiteStatistics(patients: Patient[], beta: number[]): SiteStats {
  const gradient = computeGradient(patients, beta); // 5つのfloat64値
  const hessian = computeHessian(patients, beta); // 5×5のfloat64 (25値; 15の上三角)
  const { XWX, XWY } = computeWeightedStats(patients, beta); // 6×6 + 6のfloat64
  const metadata = { nPatients: patients.length };
  // ペイロード: 約584バイト (完全行列) または約384バイト (コンパクト上三角符号化)
  return { gradient, hessian, XWX, XWY, metadata };
}

// 中央集約機 – メモリ制約のあるバッチでサイトを処理
function federatedCausalInference(sites: Site[]): CausalEffect {
  let beta = initialize(); // 傾向係数
  const allOutcomeStats: OutcomeStats[] = [];

  // 傾向: バッチあたり1回のNewtonステップ (追加のサイト通信なし)
  for (const batch of inBatchesOf(sites, BATCH_SIZE)) {
    const batchStats = batch.map(s => computeSiteStatistics(s.patients, beta));

    const G = sum(batchStats.map(s => s.gradient));
    const H = sum(batchStats.map(s => s.hessian));
    const delta = inv(H) * G; // Newtonステップ
    beta = beta + delta; //  $\beta$ が安定化 (10億人ランのバッチあたり  $||\Delta\beta|| / ||\beta||$ )

    allOutcomeStats.push(...batchStats);
  }

  // アウトカム: 全サイトにわたるシングルパス集約 (全バッチにわたって収集)
  const XWX_total = sum(allOutcomeStats.map(s => s.XWX));
  const XWY_total = sum(allOutcomeStats.map(s => s.XWY));
  const theta = inv(XWX_total) * XWY_total;
  return { ate: theta[1] };
  // se: sqrt(inv(XWX_total)[1][1]) // testOptimized.jsではまだ実装されていない
}
```

S3. ハードウェア仕様

CPU: 24論理コア (Windows上のWSL2、`os.cpus().length`による全コア利用)

OS: Linux 6.6.87.2-microsoft-standard-WSL2

Node.js: v18+

RAM: 100万人シミュレーションでピーク<1 GB ; 10億人シミュレーションで<3 GB

ストレージ: 結果に約10 MB (生の患者データは保存されない; ストリーミング生成)

測定パフォーマンス (2026年4月27日):

100万患者 (10サイト): 0.223秒、4,484,304 pts/s、24コア

1億患者 (100サイト): 8.635秒、11,580,775 pts/s、24コア

10億患者 (1,000サイト): 104秒、9,612,981 pts/s、24コア

著者情報

和智大二郎

独立研究者 / オープンソースソフトウェアエンジニア

メール: daijiro.wachi@gmail.com GitHub: <https://github.com/watilde> 所在地: 日本

経歴:

- ヘルスケアデータツールを構築するOSSエンジニア
- 機関所属や学術的立場なし
- 自己資金による独立研究

現在の制約:

- 実際の多機関医療データへのアクセスなし
- ヒト被験者研究のIRB承認なし
- 比較のための独自薬物警戒システムへのアクセスなし

共同研究への開放性: 訪問研究者ポジション、OMOPデータベースアクセスを持つ共同プロジェクト、またはグラント助成研究ポジションに利用可能。多機関研究に工学的専門知識を貢献できる。

S4. 10億人ランにわたる傾向スコア β の安定性

10億人ランは1,000サイトを24の42バッチで処理する。各バッチの後、中央集約機は β を更新する1回のNewtonステップを実行する。以下の表はチェックポイントの間隔 (100サイトごと = 約4バッチ) での β を記録する (測定されたランから)。

処理済み サイト	β_1 (切 片)	β_2 (年 齢)	β_3 (BMI)	β_4 (HbA1c)	β_5 (eGFR)	$ \beta $	$ \Delta\beta $
100	-1.988	2.032	4.795	2.907	-0.966	6.361	—
200	-1.999	2.011	4.854	2.925	-0.968	6.410	0.066
300	-1.973	2.012	4.806	2.903	-0.967	6.356	0.059
400	-1.980	2.011	4.859	2.885	-0.957	6.388	0.057
500	-1.961	1.995	4.752	2.922	-0.984	6.318	0.119
600	-1.983	2.008	4.852	2.904	-0.972	6.394	0.105
700	-2.020	2.001	4.930	2.927	-0.963	6.472	0.090
800	-1.957	1.995	4.804	2.906	-0.988	6.349	0.145
900	-1.989	2.024	4.802	2.906	-0.965	6.363	0.049
1000	-1.993	1.997	4.838	2.932	-0.969	6.396	0.052

主要な知見: β はゼロ勾配に単調収束しない。代わりに、安定した点の周りで変動する: $||\beta||$ は 6.318 から 6.472 の範囲 (相対範囲 2.4%) で、 $||\Delta\beta||/||\beta|| \leq 2.3\%$ (100 サイトのインクリメントあたり)。これは有限のミニバッチからのサンプリングノイズと一致している— $24 \times 100万 = 2,400$ 万患者の各バッチは母集団勾配の高品質だがわずかに異なる推定を提供する。

含意: β は収束ではなく安定化する: 形式的な収束基準 ($||G|| < \epsilon$) はシングルパス内では満たされないが、 β はバッチ間で $\pm 2.3\%$ 以内で変動する—推定量の発散ではなく有限ミニバッチからのサンプリングノイズと一致する。最終的な β は母集団傾向係数の合理的な推定値であり、結果として得られる IPW 推定値は安定している (1 億人と 10 億人の両方で interaction1 の偏差 $\leq 4.7\%$)、実際への影響は小さいことを示唆している。

チェックポイントファイル:

```
results/optimized_1billion_run/checkpoint_{100,200,...,1000}.json
```

S5. 多シード安定性テスト (100万規模)

結果の再現性を評価するために、100万規模の IPW ランを 3 つの異なるベースシードで複製した。サイト k はシード `baseSeed + k` を使用する。その他の全ての設定パラメータは同一。

ベ ー ス シ ード	Interaction1 ATE	Interaction1 n	偏差 (真 =3.0)	Interaction2 ATE	Interaction2 n	Interaction3 ATE	Interaction3 n
42	2.770	172,952	-7.7%	1.548	45,404	1.091	704
100	2.837	173,934	-5.4%	1.481	45,536	1.060	722
200	2.822	174,429	-5.9%	1.491	45,805	2.433	687

Interaction1: 全シードにわたって一貫した過小推定（範囲：5.4%～7.7%；平均6.3%）。シード間の変動（2.3パーセントポイント）は $n \approx 173,000$ でのサンプリング変動を反映し、期待される範囲内である。

Interaction2: シード間で安定した推定値（範囲：1.481～1.548）で、真の条件付きATE +1.527（26.3% interaction1重複から導出）を密に括弧する。3つのシード全てが真の値の $\pm 2\%$ 以内の推定値を生成し、IPW推定量がこのサブグループに対して良好にキャリブレーションされていることを確認する。

Interaction3: 非常に小さい n （ $n \approx 700$ ）による高い分散（1.060～2.433）。真の条件付きATEは+1.490（24.5% interaction1重複）；100万人の3つのシード全てがこれを大幅に過小推定（-28%から-30%）し、 $n \approx 700$ がIPW推定の安定化に不十分であることを確認する。1億人（ $n=63,340$ ）では、推定値は $\approx 0\%$ 偏差に収束；10億人（ $n=632,776$ ）では偏差は約-2.2%。

再現可能性: 生の結果は `results/multi_seed_test/seed_{42,100,200}/final_results.json` にある。再現するには：`node src/multiSeedTest.js`（実行時間：全3シードで合計1秒未満）。

原稿の種類：技術報告書 / 参照実装 語数：約5,000語