

成果物 □ 測定されたパフォーマンスと合成データでの検証済み正確性を持つオープンソース参照実装。実際の多施設データベースでのデータ
限界 □ 全ての検証は既知の真値を持つ合成データを使用している。実世界への適用可能性は、独立したエンジニアとして私のアクセス範囲
位置付け □ これは計算的実現可能性を確立し、実装の正確性を検証するものである。医学的発見や政策的推奨ではない。

実装	役割	推定量	通信サイズ	出力	使用箇所
run-polypharmacy.ts	負の対照（ベースライン）	インプット平均差	約100バイト	JSON、CSV、XML、セクション	JSON
testOptimized.js	提案された貢献	エンジン0000000 0000000 000	約1000バイト	JSONのみ	セクション000、000

2.3 合成データ生成

□□□□ 互換データジェネレーターを使用してカスタム多剤併用シナリオを生成した。□□□□□□□の臨床パターン□□□□を構造的に模倣し、異なる有病率レベルでシステムをテストするための□つの相互作用層を持つ：

層	有病率	埋め込み効果（□□□分□年）	臨床パターン	ラベル
□	□□□	□□□□	□□□ ステージ□□□□	一般
□	□□□□	□□□□	□□□ □□ □ ループ利尿薬	まれ
□	□□□□□□	□□□□	□□□ □□ □ ループ利尿薬 □ 年齢□□□	非常にまれ

適応症による交絡（実際のモデル、米国サイト；confStrength □ □ □ □）：

$\text{logit}(P(\text{Treatment})) = -2.0 + 0.02 \times \text{年齢}$

(confStrengthはサイト別：米国、日本、北欧、インド；係数)

高い□□□□、高齢、高い□□□は処置確率を高め、低い□□□はわずかに低下させる（腎機能が著しく低下している場合の処方減少＝ $-2.0 - 0.05 \times \text{年齢} \square \square \square$ ）。この年齢媒介の負の交絡により、未調整平均差推定量は治療効果を過小評価する□
処置患者は実際よりも改善が少なく見える（反事実的な自然経過がより悪いため）。

規模の仮定□ □ □億の構成は□ □ □ □ □サイト □ □ □ □ 万患者□ サイトを使用する。各□ □ □ 万患者のサイトは、大型学術医療センター一般化を制限する重要な単純化；

- □ 低次元交絡 □ ロジスティックモデルの □ 共変量
 - 現実：□ □ □ 以上の変数が複雑な非線形相互作用を持つ
 - 影響：陽性度違反は低次元シミュレーションのアーティファクトかもしれない
- □ 理想化された欠損 □ □ □ のランダム欠損
 - 現実：無視できない □ □ ~ □ □ □ の欠損（より病気の患者はより多くのデータが欠損している）
 - 影響：実際の傾向スコア推定はより困難になる
- □ 既知の真値 □ 埋め込み効果はプログラムされている
 - 現実：真の効果は未知かつ検証不可能
 - 影響：バイアス検出は真値が既知の場合にのみ可能
- □ 均質なサイト □ 同一のデータ生成プロセス
 - 現実：サイトは人口統計、診療、測定機器、コーディングシステムで異なる
 - 影響：実際の連合集約は異質性の下で失敗する可能性がある
- □ 未測定交絡なし □ 全ての交絡因子が観測されている

- 含意□ これらは些細な単純化ではない。実際の医療データ分析とは根本的に異なる問題を表している。結果は概念実証としてのみ解釈す

ハードウェア□ □ □ □ □ □ □ □ □ □ □ □ □ □ (□ □ □ □)、□ □ 論理コア。全てのランは利用可能な全コアを使用 (batchSize = os.cpus().length)。□ □ □ □ 年□ 月□ □ 日に検証。

規模	サイト	患者サイト	コア	処理時間	スループット (秒通信サイト合計通信
100万		1000000	10	10000秒	約1000パイ約1000000
1億	1000	100000000000	100	1000秒	約1000パイ約1000000000
10億	10000	100000000000000	1000	10000分 (1000秒)	約1000パイ約10000000000

□ 現行実装（完全行列）。コンパクトな上三角符号化では約□□□バイト□サイト（□□億では約□□□□□合計）に削減可能。

スケーラビリティ分析：

- 同一ハードウェアでの□つの規模点(□□コア)□ □□万人で□□□□秒 □ □億人で□□□秒 □ □億人で□□□秒。患者あたりの処理量は□□□□であり、□□□□の総計算量を実現。壁時計時間は□□□□コアでおよそ□ □壁時計□□□倍)はアルゴリズムの劣線形性ではない: □□□利用率の向上を反映している(□□□万人では□バッチで□□□データ□□倍、壁時計□□倍。
- スループットは□億人でピーク(□□□□□□□□□□): □バッチにわたって全□□コアが一貫して飽和している場合。□□□
- 一定の通信□約□□□□バイト□サイト(現行実装、完全行列)でサイトサイズによらず;コンパクトな上三角符号化では約□□□

再現コマンド：

[illegible]

3.2 負の対照：未調整推定量による系統的バイアスの実証（□□□万患者）

役割 □ このセクションは、傾向調整なしのナイーブな連合推定量が生成する系統的バイアスを特徴付ける。結果はセクション□□□の□

実装 `run-polypharmacy.ts`、シンプル平均差推定量、`バイト` サイト。`、`、`統計`、`値`を算出。

層	有病率		埋め込み推定値()	統計値	偏差	ラベル
						(過小推定)

層	有病率	埋め込み	推定値 ()	統計値	偏差	ラベル
0	0.0000	0.0000	0.000000	0.000000	0.000000	(符号逆転)まれ
			0.00000000			
			0.00000000			
0	0.00000000	0.0000	0.000000	0.000000	0.000000	(符号逆転)まれ
			0.00000000			
			0.00000000			

0000年0月00日に検証(00000000、サイト数000、患者数0サイト00000000、プロフィール0米国)。

再現コマンド:

```
npm run test:tier1
npm run test:tier2
npm run test:tier3
```

解釈:

層0(一般、000)0000の過小推定(00000000対埋め込み0000)だが符号は正しい。これは適応症による交絡が存在する(0.05×年齢)。未調整の処置0対照比較はそのため見かけ上の治療効果を圧縮する。非常に狭い00(00000000)はこれが系統的バ

層0(まれ、0000)0完全な符号逆転。埋め込み効果は有害(0000)だが、シンプル推定量は00000000で有益(0000検出力の失敗ではない。古典的な低検出力による型0エラー000とは異なり、これは処置群と対照群が共変量分布において根本的に異000ループ利尿薬)における構造的交絡から生じる。ループ利尿薬使用は心不全と体液貯留によって引き起こされる0

0共変量傾向モデルにはない危険因子0シンプル推定量が修正できない残余交絡を生み出す。注:セクション000では「00000000

層0(非常にまれ、00000000)0著しい過小推定(00倍小さい)。わずか000患者では、処置群と対照群は傾向スコア空間では重要な注意0これらは検出力の失敗ではない。全ての推定値は狭い信頼区間で00000000を達成している。問題は系統的バイアス推定量の誤った特定(層0)と陽性度違反(層0〜0)から0ランダムなサンプリング変動ではない。高い精度はバイアスの不在を意味し00000000。

3.3 提案推定量: 0つの規模での00000000000000000000

役割0このセクションは主要な貢献を示す000億規模の処理をサポートする連合000推定量。セクション000と同じ十分統計量集

実装0testOptimized.js、00000000000000000000推定量、約0000バイト0サイト。0つの規模行(0000万、0億

000ティアとは異なるサブグループ定義0testOptimized.jsデータジェネレーターは独立したサブグループ基準と埋め込み効果を0000000000000000患者で00000000分0年)。0000000000000000と0000000000000000はそれぞれ入院と0000ではない。全サブグループの患者は基本0000治療効果(00000000分0年)を経験し、0000000000000000基準0000かつ任意の利尿薬使用)も満たす場合は追加のブーストを得る可能性がある。これはセクション000との0の不一致も説明す0000万00000000患者をターゲットにしているが、00000000000000(raceAsian && age > 75 && bmi < 22)は実証的に00000000患者(約00000)を生成する0全く異なるサブグループ。

注:セクション000対000の比較0セクション000と000は異なるサブグループ定義、異なる推定量、異なる埋め込み効果メカ

シード安定性00つの規模全ての結果はベースシード00を使用する(サイト0はシード0000を使用)。0000万規模での多シード0000000の範囲となり、0000000000000000でのサンプリング変動と一致する。0000000000000000(0000000)はシード間で

真の条件付き000導出00000アウトカムモデルがegfrChange += treatment × (1.0 + 2.0 × interaction1_flag)であるため、任意のサブグループ0に対する真の条件付き000は:

E[eGFR効果]患者 基準を満たす患者

この重複確率は各ラン中に実証的に測定される。ランからの結果（サイト、各プロファイルサイト最もバランスの取れた推定）：

サブグループ	重複	真の条件付き
		分年
		分年

（ブーストサブグループ） hba1cBaseline > 8.0 かつ 任意の利尿薬。明示的な埋め込み分年。

規模	サブグループ	推定（）	真の効果	偏差
万				（過小）
億				（過小）
億				（過小）

（入院リスクサブグループ） raceAsian かつ かつ 埋め込み効果は入院（絶対リスク）に対するもので、ではない。真の：分年（上記から導出）。

規模	サブグループ	推定（）	真の	偏差
万				（）
億				（）
億			約	約（約）

（副作用サブグループ） egfrBaseline 30 45 かつ ループ利尿薬 かつ 埋め込み効果は副作用（絶対リスク）に対するもので、ではない。真の：分年（推定；推定は異なるサイトプロファイル分布のため）。

規模	サブグループ	推定（）	真の	偏差
万				（）
億				（）
億			約	約（約）

年 月 日に検証（、ベースシード；サイト数、患者サイト）
 解釈 真の条件付きがデータ生成モデルから正確に決定されたことで、つのサブグループにわたって一貫した状況が明らかにな
 （真、明示的に埋め込み）：の過小推定（万 億 億）。改善は万 億に集中；億超では収獲遞減。

□ □ 既知の真値 □ 埋め込み効果はプログラムされている □ 現実：真の効果は未知かつ検証不可能 □ 影響：バイアス検出は既知の真値

□ □ サイトの均質性 □ 同一のデータ分布 □ 現実：サイトは人口統計、診療、機器で異なる □ 影響：連合集約は異質性の下で失敗する可

□ □ 未測定交絡なし □ 全ての交絡因子が観測されている □ 現実：常に未測定交絡因子が存在する □ 影響：実際の応用では追加のバイ

□ □ 単純化されたアウトカム □ 線形関係 □ 現実：複雑な疾患進行、時間変動性交絡 □ 影響：実際のアウトカムモデリングは大幅により

含意 □ これらの単純化は実際の医療データとは根本的に異なる問題を表している。合成結果は技術的実現可能性を示すが、実世界のパフ

技術的限界：

- 単一マシンシミュレーションのみ □ この研究の全ての「連合」サイトは単一マシン上の並列 □ □ □ □ スレッドとして実行され
- いづれもここでは測定されていない。通信サイズ（約 □ □ □ バイト □ サイト）は理論的なプロトコルオーバーヘッドを表し、測定
- 市販ハードウェアのみ（クラウド □ □ □ ベンチマークなし）
- フォールトトレランスやセキュリティ分析なし
- □ □ □ 加速実装との比較なし
- 重みのトリミングや安定化なし □ □ □ 推定量は傾向重みを制限せず、傾向スコアのテールにおける極端な重み値に対して脆弱な
- □ □ □。この合成実験では影響は小さいように見える □ 真の条件付き □ □ □ がアウトカムモデルから正しく導出されると、全 □

4.3 実データを必要とする未解決の問題

□ 実証的な検証なしには不明：

- 実際の薬物警戒システムがまれなサブグループで陽性度違反を経験するかどうか
- □ □ 億規模が実際のまれなサブグループに十分かどうか（実際の有病率と交絡に依存）
- 合成データで観察されたバイアス解消が実際の異質なサイトに一般化するかどうか
- 連合アプローチが既存の中央集権的システムに対して実際の優位性を提供するかどうか
- □ □ □ □ 統合が実際の観察データベースでシームレスに機能するかどうか

4.4 なぜオープンソースにするのか

主要な目標 □ データアクセスを持つ研究者のための参照実装として動作するコードを共有する。

意図されたユーザー：

- □ □ □ □ 形式のデータベースを持つ薬物警戒研究者
- 連合因果推論を探索する方法論研究者
- まれなサブグループ仮説をテストするヘルスケア情報科学者

期待すること：

- □ 実際の多施設データを持つ誰かがまれなサブグループで陽性度違反が起こるかどうかをテストする
- □ それらが存在すれば、既存の方法との比較評価
- □ 有用であれば、実装へのコミュニティによる改善
- □ 有用でなければ、否定的な結果にも科学的価値がある

現実的な期待 □ ほとんどの研究者はこれを必要としないだろう。数人が有用と感ずるかもしれない。それで十分である。

4.5 将来の研究（共同研究が必要）

実際のデータで □ □ 億規模の知見を検証するには、以下が必要である：

- □ データアクセス □ 実際の □ □ □ 分析のための多機関契約
- □ □ □ 承認 □ 観察研究のための倫理委員会の許可

私は訪問研究者や技術的貢献者としての共同研究に開放的である。

これらの知見は計算的実現可能性を確立し、合成データでの実装の正確性を検証する。この種の規模依存のバイアスパターンが実際の薬物

コー下 連絡先

インストール (〇 〇 秒)

```
git clone https://github.com/watilde/Harmonia.git
cd Harmonia
npm install
npm run build
```

```
npm run test:quick # 10K患者、健全性チェック
```

セクション□□□ □ □□□ シンプル推定量（層□～□）□

```
npm run test:tier1 # 一般サブグループ (000) 0 0000000000、0000000000 対埋め込み 0000
npm run test:tier2 # まれなサブグループ (0000) 0 0000000000、0000000000 対埋め込み 0000 (符
npm run test:tier3 # 非常にまれなサブグループ (000000) 0 000000、0000000000 対埋め込み 00
```

[illegible]

層の結果 : polypharmacy-results/tier{1,2,3}/results.json、含む :

}

S3. ハードウェア仕様

[illegible]

□□□□ □□□万人シミュレーションでピーク□□□□；□□億人シミュレーションで□□□□
ストレージ□ 結果に約□□□□（生の患者データは保存されない；ストリーミング生成）

測定パフォーマンス (年 月 日) :

〇〇〇万患者(〇〇〇サイト)〇 〇〇〇〇〇秒、〇〇〇〇〇〇〇〇〇 〇〇〇〇〇、〇〇コア
 〇億患者(〇〇〇〇サイト)〇 〇〇〇〇〇〇秒、〇〇〇〇〇〇〇〇〇〇 〇〇〇〇〇〇、〇〇コア
 〇〇億患者(〇〇〇〇〇〇サイト)〇 〇〇〇〇〇秒、 〇〇〇〇〇〇〇〇〇〇 〇〇〇〇〇〇、〇〇コア

著者情報

和智大次郎

独立研究者 □ オープンソースソフトウェアエンジニア

メール
所在地 ☒ 日本

經歷 □

- ヘルスケアデータツールを構築する□□□エンジニア
- 機関所属や学術的立場なし
- 自己資金による独立研究

現在の制約

- 実際の多機関医療データへのアクセスなし
- ヒト被験者研究の□□□承認なし
- 比較のための独自薬物警戒システムへのアクセスなし

共同研究への開放性 □ 訪問研究者ポジション、□ □ □ □ データベースアクセスを持つ共同プロジェクト、またはグラント助成研究ポジシ

S4. 10億人ランにわたる傾向スコア $\hat{\mu}$ の安定性

□□億人ランは□□□□サイトを□□の□□バッチで処理する。各バッチの後、中央集約機は□を更新する□回の□□□□□ステップ（約□バッチ）での□を記録する（測定されたランから）。

処理済みサイト (切片)	(年齢)	()	()	()	()	()	()

主要な知見 はゼロ勾配に単調収束しない。代わりに、安定した点の周りで変動する： は から の範囲 (サイトのインクリメントあたり)。これは有限のミニバッチからのサンプリングノイズと一致している。 は 万 万患者の各バッチは母集団勾配の高品質だがわずかに異なる推定を提供する。

含意 は収束ではなく安定化する：形式的な収束基準 () はシングルパス内では満たされないが、 はバッチ間で 推定量の発散ではなく有限ミニバッチからのサンプリングノイズと一致する。最終的な は母集団傾向係数の合理的な推定値であり、結果

チェックポイントファイル `results/optimized_1billion_run/checkpoint_{100,200,...,1000}.json`

S5. 多シード安定性テスト (万規模)

結果の再現性を評価するために、 万規模の ランを つの異なるベースシードで複製した。サイト はシード `baseSeed + k` を使用する。その他の全ての設定パラメータは同一。

ベースシード			偏差 (真)			

全シードにわたって一貫した過小推定 (範囲： ～ ；平均)。シード間の変動 (シード間で安定した推定値 (範囲： ～) で、真の条件付き (を密に括弧する。 つのシード全てが真の値の 以内の推定値を 非常に小さい () による高い分散 (～)。真の条件付き は 重複) ； 万人の つのシード全てがこれを大幅に過小推定 (から) し、 が

再現可能性 生の結果は `results/multi_seed_test/seed_{42,100,200}/final_results.json` にある。再現するには： `src/multiSeedTest.js` (実行時間：全 シードで合計 秒未満)。

原稿の種類：技術報告書 参照実装 語数：約 語